

# מבוא למערכות לומדות- תרגיל 1

מגישה זוהר בוחניק 311142293

31 במרץ 2019

## שאלה 3:

חשבו את ההטלה של  $v = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix}$  על הוקטור  $w = \begin{pmatrix} 0 \\ -1 \\ 1 \\ 2 \end{pmatrix}$ .

נחשב:  $\langle v, w \rangle = 0 - 2 + 3 + 8 = 9$   $|w|^2 = 0 + (-1)^2 + 1^2 + 2^2 = 6$

לכן ההטלה המתבקשת היא הוקטור-  $\frac{9}{6} \begin{pmatrix} 0 \\ -1 \\ 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ -\frac{3}{2} \\ \frac{3}{2} \\ 3 \end{pmatrix}$

## שאלה 4:

חשבו את ההטלה של  $v = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix}$  על הוקטור  $w = \begin{pmatrix} 1 \\ 0 \\ 1 \\ -1 \end{pmatrix}$ .

נחשב:  $\langle v, w \rangle = 1 + 0 + 3 - 4 = 0$

$\begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$  מאונכים אזי ההטלה המתבקשת היא  $\begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$

## שאלה 7:

בעבור  $A = UDV^T$  נייצג את המטריצה  $A^{-1}$  באופן הבא:

$$A^{-1} = (UDV^T)^{-1} = (V^T)^{-1} D^{-1} U^{-1} = V D^{-1} U^T$$

כאשר  $D^{-1} = \text{diag}(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_n})$  אם נדע את צורת ה  $SVD$  של המטריצה  $A$  נוכל למצוא את  $A^{-1}$  בקלות על ידי חישוב  $D^{-1}$  בצורה הנ"ל ואז מכפלת המטריצות  $VD^{-1}U^T$  תביא לתוצאה הסופית המבוקשת.

## שאלה 8:

מצאו את ה  $SVD$  של  $C = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix}$

ראשית נחשב את המטריצה  $C^T C$

$$\begin{pmatrix} 5 & -1 \\ 5 & 7 \end{pmatrix} \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} = \begin{pmatrix} 26 & 18 \\ 18 & 74 \end{pmatrix}$$

כעת נמצא את הערכים העצמיים של המטריצה  $C^T C$   $\det(C^T C - \lambda I) = \det \begin{pmatrix} 26 - \lambda & 18 \\ 18 & 74 - \lambda \end{pmatrix} = (26 - \lambda)(74 - \lambda) - 18^2 = \lambda^2 - 100\lambda + 1600 = (\lambda - 20)(\lambda - 80) = 0$

כלומר קיבלנו כי  $\lambda_1 = 20, \lambda_2 = 80$  הערכים העצמיים של  $C^T C$   
 עכשיו נחשב את הוקטורים העצמיים, זאת בעזרת מציאת בסיסים למרחבים העצמיים של  $C^T C$ :

$$C^T C - 20I = \begin{pmatrix} 6 & 18 \\ 18 & 54 \end{pmatrix}$$

נשים לב כי הטור השני הוא פי שלוש מהטור הראשון ולכן  $v_1 = \begin{pmatrix} -3 \\ 1 \end{pmatrix}$  הוא בסיס מתאים עבור  $\lambda = 20$

$$C^T C - 80I = \begin{pmatrix} -54 & 18 \\ 18 & -6 \end{pmatrix}$$

באופן דומה הטור הראשון הוא פי שלוש בערך מוחלט מהטור השני ולכן  $v_2 = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$  הוא בסיס מתאים עבור  $\lambda = 80$   
 ננרמל את הוקטורים

$$\|v_1\| = \sqrt{\langle v_1, v_1 \rangle} = \sqrt{9+1} = \sqrt{10}$$

$$\|v_2\| = \sqrt{\langle v_2, v_2 \rangle} = \sqrt{9+1} = \sqrt{10}$$

$$V = \begin{pmatrix} \frac{-3}{\sqrt{10}} & \frac{1}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} & \frac{3}{\sqrt{10}} \end{pmatrix} = V^T$$

הערכים הסינגולריים של  $C^T C$  הם  $\sigma_1 = \sqrt{20}, \sigma_2 = \sqrt{80}$  ולכן

$$\Sigma = \begin{pmatrix} \sqrt{20} & 0 \\ 0 & \sqrt{80} \end{pmatrix}$$

לבסוף נחשב את  $U$  בעזרת  $CV = U\Sigma$

$$CV = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} \begin{pmatrix} \frac{-3}{\sqrt{10}} & \frac{1}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} & \frac{3}{\sqrt{10}} \end{pmatrix} = \begin{pmatrix} \frac{-10}{\sqrt{10}} & \frac{20}{\sqrt{10}} \\ \frac{10}{\sqrt{10}} & \frac{20}{\sqrt{10}} \end{pmatrix} = \begin{pmatrix} -\sqrt{10} & 2 \cdot \sqrt{10} \\ \sqrt{10} & 2 \cdot \sqrt{10} \end{pmatrix} = U\Sigma = U \cdot \begin{pmatrix} \sqrt{20} & 0 \\ 0 & \sqrt{80} \end{pmatrix}$$

כלומר:

$$\begin{pmatrix} -\sqrt{10} & 2 \cdot \sqrt{10} \\ \sqrt{10} & 2 \cdot \sqrt{10} \end{pmatrix} = U \cdot \begin{pmatrix} \sqrt{20} & 0 \\ 0 & \sqrt{80} \end{pmatrix}$$

$$x_{11} \cdot \sqrt{20} = -\sqrt{10} \Rightarrow x_{11} = -\frac{\sqrt{10}}{\sqrt{20}} = -\frac{1}{\sqrt{2}}$$

$$x_{12} \cdot \sqrt{80} = 2\sqrt{10} \Rightarrow x_{12} = \frac{2\sqrt{10}}{\sqrt{80}} = \frac{1}{\sqrt{2}}$$

$$x_{21} \cdot \sqrt{20} = \sqrt{10} \Rightarrow x_{21} = \frac{1}{\sqrt{2}}$$

$$x_{22} \cdot \sqrt{80} = 2\sqrt{10} \Rightarrow x_{22} = \frac{2\sqrt{10}}{\sqrt{80}} = \frac{1}{\sqrt{2}}$$

$$\Rightarrow U = \begin{pmatrix} -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

## שאלה 9:

תהי  $A \in M_{m \times n}(\mathbb{R})$  מדרגה  $r$ , ותהי  $C_0 = A^T A$ . נגדיר  $b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|}$  כאשר  $b_0$  מאותחל רנדומלית. צריך להראות כי  $\lim_{k \rightarrow \infty} b_k = v_1$  כאשר  $v_1$  הוא וקטור סינגולרי הימני ביותר התואם לערך הסינגולרי הגדול ביותר של  $C_0$ . ניתן להניח כי  $\lambda_1 > \lambda_2$ .  
 כאשר  $\lambda_1, \dots, \lambda_n$  הערכים העצמיים של  $C_0$ ,  $v_1, \dots, v_n$  ו"ע של  $C_0$ , וכי  $b_0 = \sum_{i=1}^n a_i v_i$ ,  $a_1 \neq 0$ . נייצג את  $C_0$  על ידי  $EVD$ :  
 $C_0 = V D V^T$   
 נמצא את  $b_1$  בעזרת  $b_0$ :

$$b_1 = \frac{C_0 b_0}{\|C_0 b_0\|} = \frac{V D V^T \cdot \sum_{i=1}^n a_i v_i}{\|V D V^T \cdot \sum_{i=1}^n a_i v_i\|}$$

$$V D V^T \cdot \sum_{i=1}^n a_i v_i = V \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} V^T \cdot V \cdot \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix} = V \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \cdot I_n \cdot \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix} = V \cdot \begin{bmatrix} \lambda_1 a_1 \\ \vdots \\ \lambda_n a_n \end{bmatrix} = \sum_{i=1}^n \lambda_i \cdot v_i \cdot a_i$$

כלומר קיבלנו:

$$b_1 = \frac{\sum_{i=1}^n \lambda_i \cdot v_i \cdot a_i}{\|\sum_{i=1}^n \lambda_i \cdot v_i \cdot a_i\|}$$

**טענה:** לכל  $k$  מתקיים

$$b_k = \frac{\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i}{\|\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i\|}$$

נראה באינדוקציה:  
בסיס ראינו כי

$$b_1 = \frac{\sum_{i=1}^n \lambda_i \cdot v_i \cdot a_i}{\|\sum_{i=1}^n \lambda_i \cdot v_i \cdot a_i\|}$$

צעד נניח עבור  $k$  ונוכיח עבור  $k+1$ :  
 מהנחת האינדוקציה מתקיים:

$$b_k = \frac{\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i}{\|\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i\|}$$

לכן נציב:

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{V D V^T \cdot b_k}{\|V D V^T \cdot b_k\|}$$

מתקיים-

$$C_0 b_k = V D V^T \cdot b_k = V D V^T \cdot \frac{\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i}{\|\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i\|} = \frac{V D V^T \cdot V \cdot \begin{bmatrix} \lambda_1^k a_1 \\ \vdots \\ \lambda_n^k a_n \end{bmatrix}}{\|\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i\|} = \frac{V \cdot \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \cdot \begin{bmatrix} \lambda_1^k a_1 \\ \vdots \\ \lambda_n^k a_n \end{bmatrix}}{\|\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i\|}$$

$$V \cdot \begin{bmatrix} \lambda_1^{k+1} a_1 \\ \vdots \\ \lambda_n^{k+1} a_n \end{bmatrix} = \frac{\sum_{i=1}^n v_i \lambda_i^{k+1} a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|} = \frac{\sum_{i=1}^n v_i \lambda_i^{k+1} a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|}$$

נשים לב כי

$$b_{k+1} = \frac{\frac{\sum_{i=1}^n v_i \lambda_i^{k+1} a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|}}{\left\| \frac{\sum_{i=1}^n v_i \lambda_i^{k+1} a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|} \right\|} = \frac{\frac{\sum_{i=1}^n v_i \lambda_i^{k+1} a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|}}{\frac{1}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|} \cdot \left\| \sum_{i=1}^n v_i \lambda_i^{k+1} a_i \right\|}} = \frac{\sum_{i=1}^n v_i \lambda_i^{k+1} a_i}{\left\| \sum_{i=1}^n v_i \lambda_i^{k+1} a_i \right\|}$$

כלומר הוכחנו את צעד האינדוקציה כנדרש.

כעת נשתמש בביטוי הזה של  $b_k$  על מנת לחשב את הגבול המבוקש:

$$\lim_{k \rightarrow \infty} b_k = \lim_{k \rightarrow \infty} \frac{\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|} = \lim_{k \rightarrow \infty} \frac{V \cdot \begin{bmatrix} \lambda_1^k a_1 \\ \vdots \\ \lambda_n^k a_n \end{bmatrix}}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|}$$

$$= \lim_{k \rightarrow \infty} \frac{V \cdot \lambda_1^k \cdot \begin{bmatrix} 1 \\ \frac{\lambda_2^k}{\lambda_1^k} \\ \vdots \\ \frac{\lambda_n^k}{\lambda_1^k} \end{bmatrix}}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|} \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix}$$

מתקיים

$$\lim_{k \rightarrow \infty} \begin{bmatrix} 1 & & & \\ & \frac{\lambda_2^k}{\lambda_1^k} & & \\ & & \ddots & \\ & & & \frac{\lambda_n^k}{\lambda_1^k} \end{bmatrix} = \begin{bmatrix} 1 & & & \\ & 0 & & \\ & & \ddots & \\ & & & 0 \end{bmatrix}$$

כי  $\lambda_1$  הוא הערך העצמי הכי גדול ולכן לכל  $i \neq 1$  מתקיים  $\left(\frac{\lambda_i}{\lambda_1}\right)^k = 0$

לכן בתצוגה  $\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i$  ניתן לראות כי כאשר  $k \rightarrow \infty$  אנו מקבלים כי:  $\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \rightarrow v_1 a_1 \lambda_1^k$  מכאן נובע לבסוף-

$$\lim_{k \rightarrow \infty} b_k = \lim_{k \rightarrow \infty} \frac{\sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i}{\left\| \sum_{i=1}^n \lambda_i^k \cdot v_i \cdot a_i \right\|} = \lim_{k \rightarrow \infty} \frac{v_1 a_1 \lambda_1^k}{\left\| v_1 a_1 \lambda_1^k \right\|} = v_1$$

זאת כיוון ש  $\|v_1\| = 1$  וכיוון ש  $\frac{a_1 \lambda_1^k}{|a_1| |\lambda_1^k|} = 1$  (בהנחה שהערכים חיוביים).

## שאלה 14:

יהי  $V$  תת מרחב של  $\mathbb{R}^d$  מממד  $k$ , ויהי  $v_1, \dots, v_k \in \mathbb{R}^d$  בסיס אורתונורמלי של  $V$ . תהי  $P = \sum_{i=1}^k v_i v_i^T$  מטריצת הטלה לתת המרחב  $V$ . צל-  $P$  סימטרית.

הוכחה ראשית נשים לב כי  $v_i v_i^T$  היא מטריצה סימטרית לכל  $i$ . זאת כיוון שמתקיים  $(v_i v_i^T)^T = (v_i^T)^T v_i^T = v_i v_i^T$ . שנית, נשים לב כי  $P$  היא סכום של מטריצות סימטריות וסכום של שתי מטריצות סימטריות שומר על תכונת הסימטריה: יהיו  $A, B$  סימטריות אזי:  $(A+B)^T = A^T + B^T = A + B$ , כלומר  $A+B$  סימטרית. מכאן  $P$  סימטרית.

## שאלה 15:

צל  $v_1, \dots, v_k$  הם וקטורים עצמיים של  $P$  עם ערך עצמי  $\lambda = 1$ . כלומר צריך להראות כי לכל  $i \in [k]$  מתקיים  $P \cdot v_i = v_i$ .

$$P \cdot v_i = \left( \sum_{j=1}^k v_j v_j^T \right) \cdot v_i = \sum_{j=1}^k v_j v_j^T v_i = v_1 v_1^T v_i + v_2 v_2^T v_i + \dots + v_i v_i^T v_i + \dots + v_k v_k^T v_i$$

כיוון ש  $v_i \perp v_j$  לכל  $i \neq j$  אזי המכפלה  $v_j^T v_i = 0$ , לכן נקבל שה"כ כי

$$P \cdot v_i = v_i v_i^T v_i$$

אמנם, כיוון ש  $v_i$  הוא אורתונורמלי הנורמה שלו שווה ל-1, והרי  $v_i^T v_i = \|v_i\|^2 = 1$ , כלומר קיבלנו  $P \cdot v_i = v_i$  כנדרש.

## שאלה 16:

כתבו  $EVD$  אפשרי ל- $P$ .

ראשית ניקח את הבסיס  $v_1, \dots, v_k$  של  $V$  ונשלים אותו לבסיס אורתונורמלי של  $\mathbb{R}^d$   $v_1 = u_1, \dots, v_k = u_k, u_{k+1}, \dots, u_d$

$$D = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & & 0 & \\ & & & & \ddots \\ & & & & & 0 \end{bmatrix} \in \mathbb{R}^{d \times d}$$

תהי  $V = \begin{bmatrix} | & | & & | \\ u_1 & u_2 & \dots & u_d \\ | & | & & | \end{bmatrix}$  מטריצה אורתוגונלית, אזי  $P = V D V^T$  כאשר

$(\mathbb{R})^{d \times d}$  (מספר האחדות הוא לפחות  $k$ , והשאר אפסים).

## שאלה 17:

$$P^2 = P P^T = P^T P = P$$

הראו כי  $P^2 = P P^T = P^T P = P$ . נשים לב כי  $P$  היא מטריצת הטה, מהגדרה לאחר שמבצעים הטלה על וקטור כלשהו, אם נבצע שוב הטלה לא יקרה כלום, כלומר להטיל פעמיים זה בדיוק כמו להטיל פעם אחת ולכן  $P = P^2$ . בנוסף, בעזרת טענה מסעיף 18 ניתן להסיק את השיוויון:

$$(I - P) P = 0 \Rightarrow IP - P^2 = 0 \Rightarrow IP = P^2 \Rightarrow P = P^2$$

## שאלה 19:

הראו כי לכל  $x \in V$  מתקיים  $Px = x$ . בשאלה 15 ראינו כי כל וקטור בבסיס  $v_1, \dots, v_k$  של  $V$  מקיים  $Pv_i = v_i$ . עבור  $x \in V$  מתקיים  $x = a_1 v_1 + \dots + a_k v_k$  בעבור  $a_1, \dots, a_k \in \mathbb{R}$  סקלרים כלשהם. לכן

$$Px = P \cdot (a_1 v_1 + \dots + a_k v_k) = P \cdot a_1 v_1 + \dots + P \cdot a_k v_k = a_1 \cdot (P \cdot v_1) + \dots + a_k \cdot (P \cdot v_k) =$$

$$= a_1 \cdot (v_1) + \dots + a_k \cdot (v_k) = x$$

כנדרש בשאלה.

## שאלה 20:

נחשב את היעקוביאן של

$$f(\sigma) = U \cdot \text{diag}(\sigma) U^T x$$

נסמן

$$\begin{aligned} \sigma &= \begin{bmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{bmatrix} \\ U \cdot \text{diag}(\sigma) U^T x &= \begin{bmatrix} | & & | \\ u_1 & \cdots & u_n \\ | & & | \end{bmatrix} \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \begin{bmatrix} - & - & u_1 & - & - \\ & & \vdots & & \\ - & - & u_n & - & - \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \\ &= \begin{bmatrix} | & & | \\ u_1 & \cdots & u_n \\ | & & | \end{bmatrix} \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \begin{bmatrix} \langle u_1, x \rangle \\ \vdots \\ \langle u_n, x \rangle \end{bmatrix} = \begin{bmatrix} | & & | \\ u_1 & \cdots & u_n \\ | & & | \end{bmatrix} \begin{bmatrix} \lambda_1 \cdot \langle u_1, x \rangle \\ \vdots \\ \lambda_n \cdot \langle u_n, x \rangle \end{bmatrix} = \\ &= \begin{bmatrix} | & & | \\ u_1 & \cdots & u_n \\ | & & | \end{bmatrix} \left( \begin{bmatrix} \lambda_1 \cdot \langle u_1, x \rangle \\ 0 \\ \vdots \\ 0 \end{bmatrix} + \dots + \begin{bmatrix} 0 \\ \vdots \\ 0 \\ \lambda_n \cdot \langle u_n, x \rangle \end{bmatrix} \right) = \\ &= \lambda_1 \cdot \langle u_1, x \rangle \cdot \begin{bmatrix} | \\ u_1 \\ | \end{bmatrix} + \dots + \lambda_n \cdot \langle u_n, x \rangle \begin{bmatrix} | \\ u_n \\ | \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n \lambda_i \cdot \langle u_i, x \rangle [u_i]_1 \\ \vdots \\ \sum_{i=1}^n \lambda_i \cdot \langle u_i, x \rangle [u_i]_n \end{bmatrix} \end{aligned}$$

קיבלנו בעצם  $n$  פונקציות  $f_j : \mathbb{R}^n \rightarrow \mathbb{R}$  כאשר  $j \in [n]$

$$f_j(\sigma) = \sum_{i=1}^n \lambda_i \cdot \langle u_i, x \rangle [u_i]_j$$

נחשב את הגרדיאנט של  $f_j$ :

$$\frac{\partial f_j(\sigma)}{\partial \lambda_k} = \langle u_k, x \rangle [u_k]_j$$

$$\nabla f_j(\sigma) = \begin{bmatrix} \langle u_1, x \rangle [u_1]_j \\ \vdots \\ \langle u_n, x \rangle [u_n]_j \end{bmatrix}$$

לכן לבסוף נקבל את היעקוביאן הבא:

$$\begin{bmatrix} \langle u_1, x \rangle [u_1]_1 & \cdots & \langle u_n, x \rangle [u_n]_1 \\ & \vdots & \\ \langle u_1, x \rangle [u_1]_n & \cdots & \langle u_n, x \rangle [u_n]_n \end{bmatrix} = \begin{bmatrix} (\nabla f_1(\sigma))^T \\ \vdots \\ (\nabla f_n(\sigma))^T \end{bmatrix}$$

## שאלה 21:

מתקיים

$$f(\sigma) = U \cdot \text{diag}(\sigma) \cdot U^T x$$

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2$$

צריך לחשב את הגרדיאנט של  $h$ . נגדיר  $g: \mathbb{R}^n \rightarrow \mathbb{R}$   $g(\bar{u}) = \frac{1}{2} \|\bar{u} - y\|^2$  אזי  $h = g \circ f(\sigma)$  ומכלל השרשרת  $J_\sigma(g \circ f) = J_{f(\sigma)}(g) \cdot J_\sigma(f)$  נשים לב כי את הגרדיאנט של  $g$  אנו מכירים מהכיתה כלומר  $\Delta g(u) = 2 \cdot \frac{1}{2} (\bar{u} - y)^T = (\bar{u} - y)^T$  לכן

$$J_\sigma(g \circ f) = J_{f(\sigma)}(g) \cdot J_\sigma(f) = \left( \underbrace{U \cdot \text{diag}(\sigma) \cdot U^T x - y}_{f(\sigma)} \right)^T \cdot \begin{bmatrix} \langle u_1, x \rangle [u_1]_1 & \cdots & \langle u_n, x \rangle [u_n]_1 \\ & \vdots & \\ \langle u_1, x \rangle [u_1]_n & \cdots & \langle u_n, x \rangle [u_n]_n \end{bmatrix}$$


## שאלה 22:

נמשיך את החישוב עבור  $i \neq j$ :

$$g(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}$$

$$\frac{\partial S_i}{\partial a_j} = \frac{-e^{z_i} \cdot e^{z_j}}{\left(\sum_{k=1}^K e^{z_k}\right)^2} = -\frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \cdot \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} = -S_i \cdot S_j$$


שאלה 23:



בבחירה של נקודות רנדומליות קיבלנו את הגרף הנ"ל



## שאלה 24:



נציג את מטריצת ה- $cov$  בשתי הצורות:  
אנליטית-

$$SCS^T = \begin{bmatrix} 0.01 & 0 & 0 \\ 0 & 0.25 & 0 \\ 0 & 0 & 4 \end{bmatrix}$$


נומרית-

$$\hat{C} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^T = \frac{X \cdot X^T}{50000 - 1} =$$

```
cov matrix numeric calculation:
[[ 9.92371909e-03 -1.75578080e-04 -8.59447728e-04]
 [-1.75578080e-04  2.48545643e-01 -1.11313226e-02]
 [-8.59447728e-04 -1.11313226e-02  4.03725894e+00]]
```

נראה כי עדיין אין תלות בין ה- $x$  וה- $y$  או ה- $z$ . אין השפעה של עליית ה- $x$  על ערכי ה- $y$  או ה- $z$  בצורה בולטת. ניתן לראות כי מטריצת ה- $cov$  אלכסונית, כלומר המשתנים המקריים בלתי מתואמים. בהצגה נומרית קיבלנו ערכים מאוד דומים למטריצת ה- $cov$  בחישוב האנליטי.

## שאלה 25:



נציג את מטריצת ה-cov בשתי הצורות:  
אנליטית-

$$RCR^T =$$


```
cov matrix analytic calculation:
[[ 2.04288197 -1.88123062  0.62605709]
 [-1.88123062  1.75381475 -0.60694516]
 [ 0.62605709 -0.60694516  0.46330327]]
```

נומרית-

$$\hat{C} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^T = \frac{X \cdot X^T}{50000 - 1} =$$


```
cov matrix numeric calculation:
[[ 2.03892359 -1.87860185  0.62783799]
 [-1.87860185  1.75193748 -0.60813309]
 [ 0.62783799 -0.60813309  0.46504032]]
```

נראה כי נוצרה תלות לינארית בין הפרמטרים לאחר הסיבוב. נשים לב כי במטריצת ה-cov השתנתה כך שניתן לראות כי המשתנים לא בלתי מתואמים.



בגרף אחרי השיטוח וביטול ציר ה  $z$  ניתן לראות כי הנקודות שמרו על הצורה הלינארית שלהן, גם בדר מימד. הצפיפות המרכזית היא במרכז הגרף וככל שמתקרבים לקצוות הצפיפות יורדת

## שאלה 27:



לאחר שהוספנו את התנאי קיבלנו צורה מוקטנת של הגרף הקודם. בעצם ניקינו את כל הנקודות שחורגות מהגבול הנתון ואז כשיטחנו את הנתונים לדו מימד קיבלנו כיווץ של הגרף הקודם שהיה ללא תנאים נוספים. אמנם הצפיפות נשמרה.

## שאלה 28:

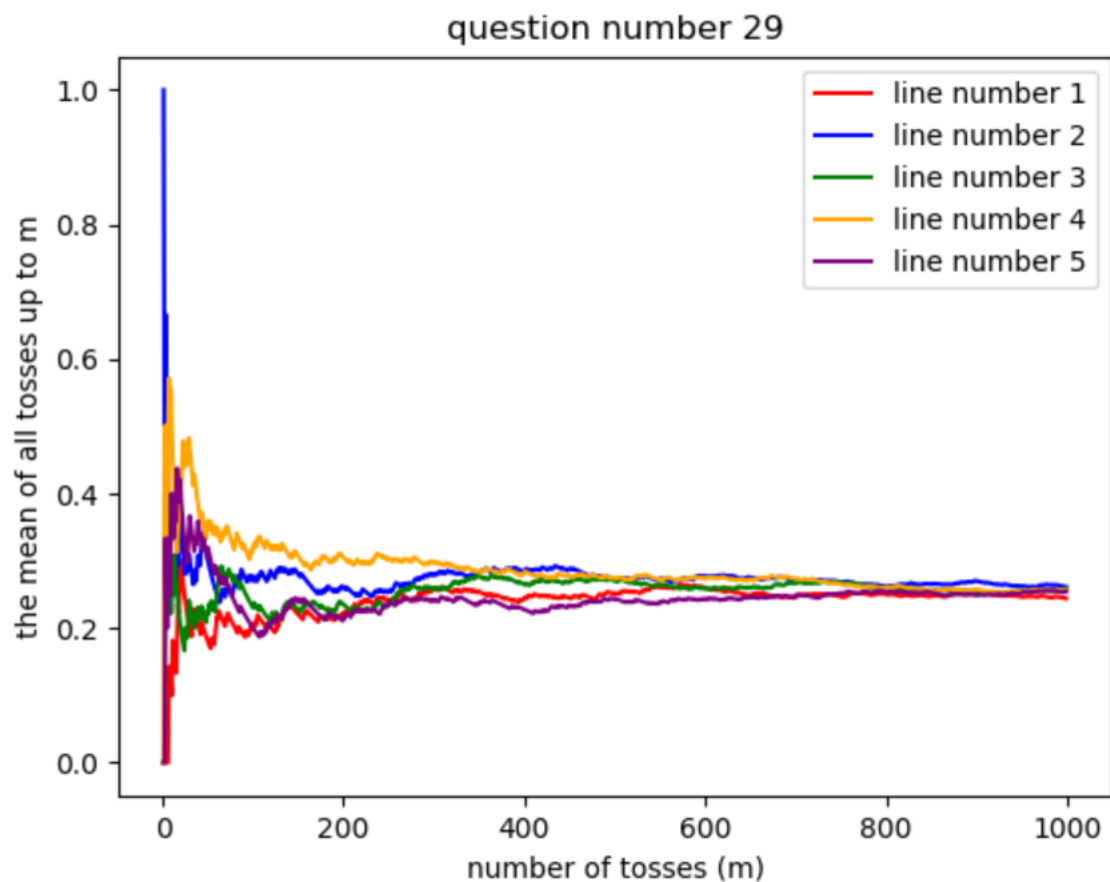
ה- $m$  שמצאנו היה

$$m = \lceil \frac{1}{2\varepsilon^2} \cdot \log\left(\frac{4}{\delta}\right) \rceil$$


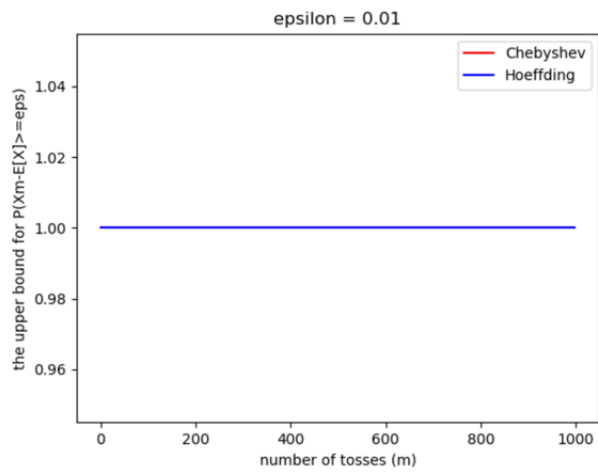
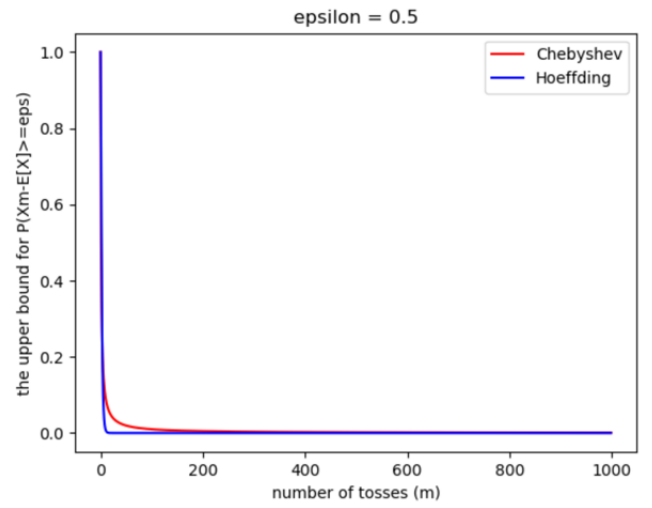

על ידי שימוש בחסמים של הופדינג וצ'בישב מצאנו את  $m$  כך שבשימוש באלגוריתם  $A$  שראינו בכיתה נוכל לקבוע את  $p$  בדיוק הקירוב  $\varepsilon$  ובטחון  $\delta$ .


חסמנו בעצם את מורכבות המדגם  $m(\varepsilon, \delta)$  על ידי שני חסמים, בתחילה  $m(\varepsilon, \delta) \leq \lceil \frac{1}{4\varepsilon^2} \cdot \frac{1}{\delta} \rceil$ , ואז שיפרנו אותו לידי  $m(\varepsilon, \delta) \leq \lceil \frac{1}{2\varepsilon^2} \cdot \log\left(\frac{2}{\delta}\right) \rceil$ , ואז השתמשנו בחסמים להוכחה של האלגוריתם  $A$ .

שאלה 29:  
א.




נצפה שככל ש  $m$  גדל כך התוצאות בין השורות השונות יהיו יותר דומות, כלומר הממוצע שיתקבל בכל שורה יהיה דומה, וכך גם קיבלנו בגרף ככל ש  $m$  גדל כך הממוצעים התקרבו אחד לשני, כלומר הערך המתקבל יותר מהימן.


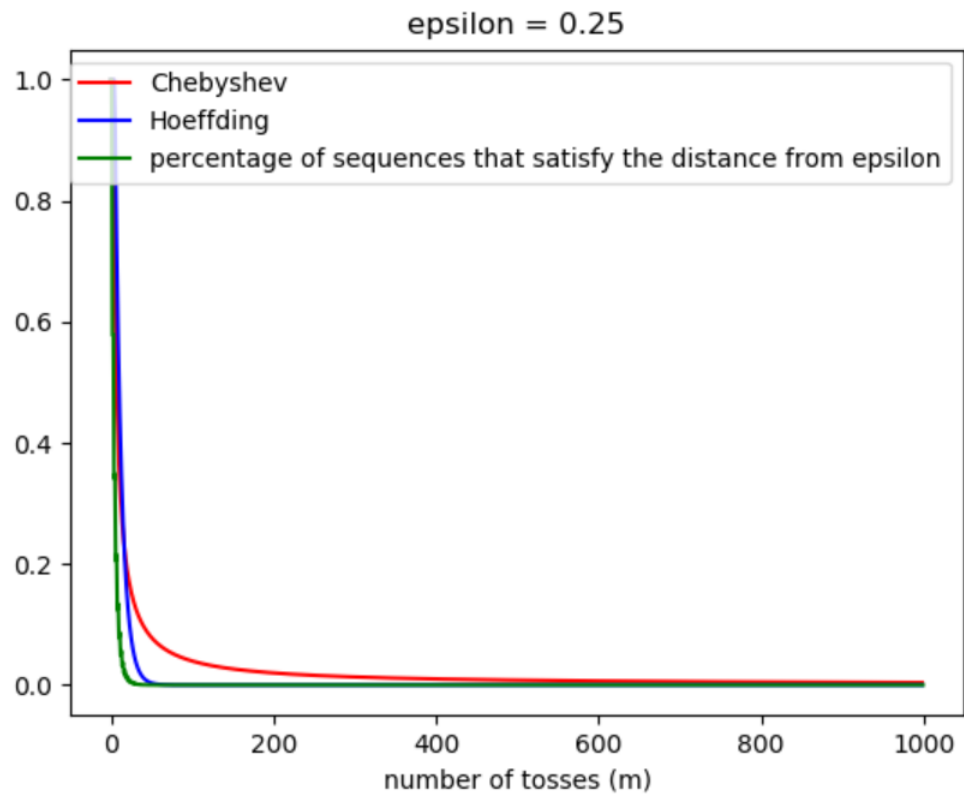




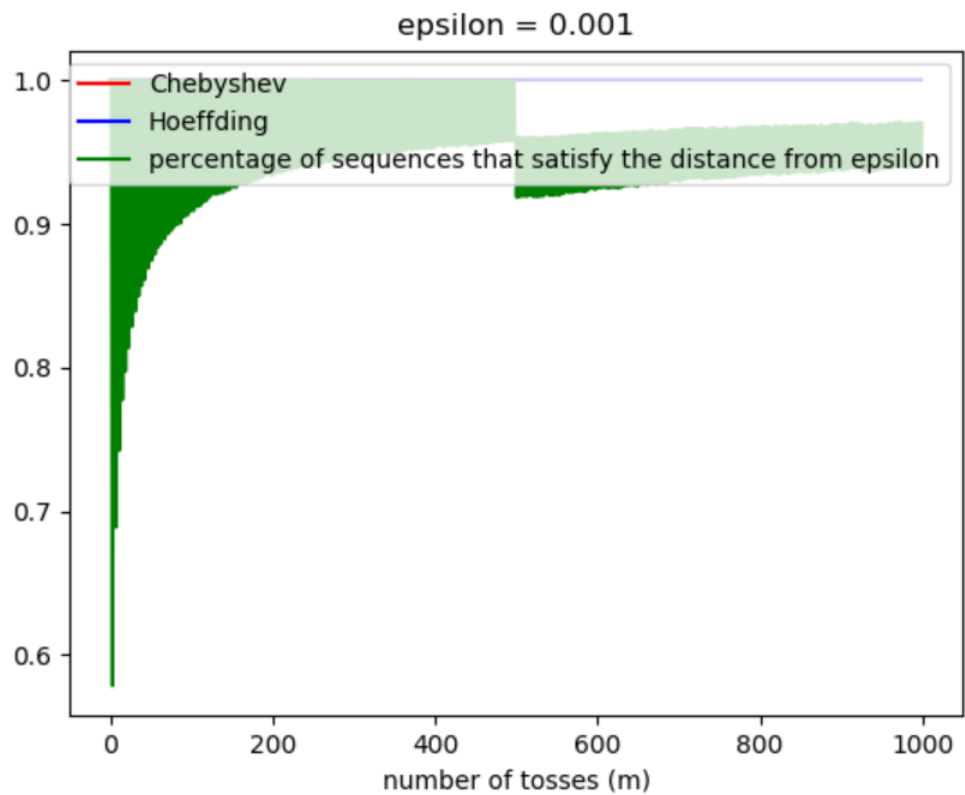
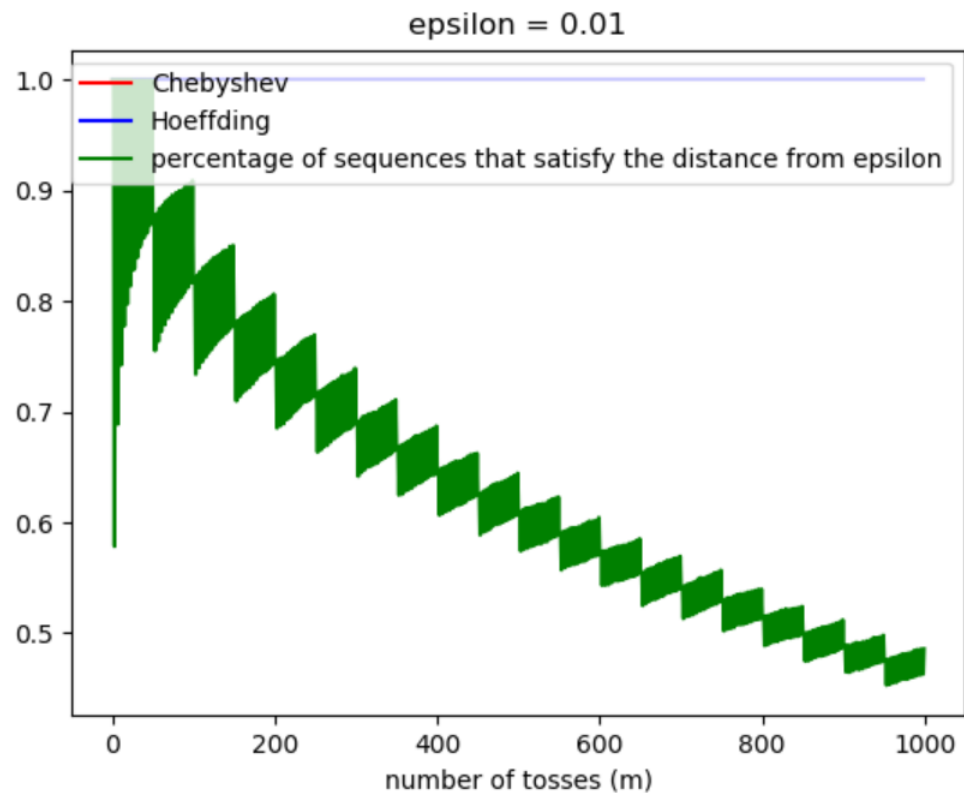
בגרפים האלו אנו רואים כי החסם של הופדינג ושל צ'בישב משתפר וקטן ככל שגדל  $m$ . זאת כיוון שמספר הדגימות עולה, כך נצפה שממוצע הדגימות יתקרב לתוחלת וההסתברות שהמרחק הזה יהיה גדול מאפסילון קטנה יותר ויותר והחסמים יכולים להבטיח גבול עליון על הטעות, אשר הוא קטן מ-1 ויש לו משמעות. בעבור  $\epsilon$  קטנים במיוחד ניתן לראות כי גם עבור  $m = 1000$  עדיין החסמים של הופדינג וצ'בישב לא יכולים לספק חסם טוב יותר מ-1. זה מאוד הגיוני כי ככל שאפסילון קטן כך קשה להבטיח שההסתברות שהמרחק בין הממוצע לתוחלת יהיה קטן מאותו  $\epsilon$ .

ג.









הגרפים הבאים מחשבים בנוסף בעבור כל  $m$  כמה מתוך הסבבים של הדגימות היו בממוצע רחוקים מהתוחלת של המשתנה המקרי של הטלת המטבע יותר מ- $\epsilon$ . מה שנצפה לראות זה שככל ש- $m$  גדל, כלומר אנו מסתכלים על יותר דגימות, לפי החוק של המספרים הגדולים נצפה שהממוצע יתקרב לתוחלת כך שיהיו כמה שפחות סבבים שלא מקיימים את התנאי (רחוקים מידי מ- $\epsilon$ ). נראה כי ככל

ש  $\varepsilon$  יותר קטן כך קשה לקיים את התנאי ואחוז הדגימות שבממוצע רחוקות מהתוחלת גדל. זה מאוד הגיוני כי ככל שאפסילון קטן כך הסבירות לטעות גדולה מאפסילון עולה.